Andrii Dokaniev
id:128365

6/12/2024

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológii

MNIST klasifikátor

Zadanie č. 3a

Andrii Dokaniev
id:128365

Contents

Andrii Dokaniev
id:128365

6/12/2024

Popis zadania

Úlohou bolo vytvoríte neurónovú sieť na klasifikáciu ručne písaných číslic z dátového súboru MNIST. Zobrať súbor údajov zo 60 000 obrázkov na trénovanie a 10 000 obrázkov na testovania, veľkosť obrázkov je 28 x 28 a reprezentuje jednu číslicu od 0 do 9.

Použiť doprednú neurónovú sieť (viacvrstvový perceptrón) a natrénujte ju pomocou algoritmov SGD, SGD s momentom a ADAM, použiť knižnicu PyTorch. Okrem trénovacej a testovacej chyb, odmerať aj presnosť modelu (t. j. koľkokrát model predikoval správnu triedu na testovacej množine).

Reprezentácia údajov a konfigurácie

Na trénovacie a testovacie dáta použijeme údaje z databázy MNIST.

```
"""Datasets"""
train_dataset = torchvision.datasets.MNIST(root='./data', train=True,
download=True, transform=transform)
test_dataset = torchvision.datasets.MNIST(root='./data', train=False,
download=True, transform=transform)

"""DataLoaders"""
train_loader = DataLoader(train_dataset, batch_size=train_batch_size,
shuffle=True)
test_loader = DataLoader(test_dataset, batch_size=test_batch_size,
shuffle=False)
```

Veľkosť dávky (batch) je zaznamenaná v konfiguračnom súbore, ktorý vyzerá nasledovne:

```
[Settings]
load_model = False
optimizer(sgd, sgd_momentum, adam) = adam
epoch_count = 20
train_batch_size = 64
test_batch_size = 64
show_confusion_matrix = False
learning_rate = 0.001
momentum = 0.9
```

Andrii Dokaniev
id:128365

6/12/2024

Postup riešenia

Na zatáčku programu bolo importovane knižnica pre náhodne generovanie, matematická Tato cast

```
import torch
import torchvision
import torchvision.transforms as transforms
from torch.utils.data import DataLoader
import torch.nn.functional as F
import torch.optim as optim
import torch.nn as nn
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix
import seaborn as sns
import time
import os
import configparser
from colorama import Fore, Style, init
```

Obsahuje všetky potrebné knižnice pre Torch a MNIST klasifikátor. Okrem toho aj knižnicu pre načrtnutie štatistických grafov, knižnicu na sledovanie času, cesty k súborom, farebné výstupy a konfiguračný súbor.

Všetky potrebné knižnice je potrebne nainštalovať použitím príkazu “pip install <názov knižnice>“.

Po implementácii knižníc bolo zadefinovaných niekoľko najdôležitejších funkcií, takých ako:

```
"""Parameters for the configuration file"""
load_model = None
auto_save_model = None
optimizer = None
epoch_count = 0
train_batch_size = 0
test_batch_size = 0
show_confusion_matrix = False
learning_rate = 0
momentum = 0
```

Ďalej sú určené začiatočné parametre, ak konfiguračný súbor neexistuje, s následným načítaním konfiguračných parametrov zo súboru.

Ďalej nasleduje trieda MLP modelu:

```
class MLP(nn.Module):
    def __init__(self):
        super(MLP, self).__init__()
        self.fc1 = nn.Linear(784, 256)
        self.fc2 = nn.Linear(256, 64)
        self.fc3 = nn.Linear(64, 10)
```

```
        #self.dropout = nn.Dropout(0.2)

    def forward(self, x):
        """Available activation functions: ReLU, Sigmoid, Tanh"""
        x = x.view(-1, 784)
        x = torch.relu(self.fc1(x))
        #x = self.dropout(x)
        x = torch.relu(self.fc2(x))
        x = self.fc3(x)
        return x
```

V ktorej je nastavene sloji modelu a aktivačne funkcie pre rôzne sloji. Ďalej, ak treba načítavame už existujúci model, nastavujem chybovú funkciu a metód na trénovanie modelu.

```
if load_model == False:
    model = MLP()
else:
    model = torch.load('mnist_model.pth')
    print(Fore.YELLOW + 'Model loaded')

"""Loss function"""
criterion = nn.CrossEntropyLoss()

"""Optimizers"""
if optimizer == 'sgd':
    optimizer = optim.SGD(model.parameters(), lr=learning_rate)
elif optimizer == 'sgd_momentum':
    optimizer = optim.SGD(model.parameters(), lr=learning_rate,
momentum=momentum)
elif optimizer == 'adam':
    optimizer = optim.Adam(model.parameters(), lr=learning_rate)
```

Ďalej ide metóda na trénovanie modelu a na testovanie. Tato metóda obsahuje informácie po každej epoche, ako: úspešnosť trénovania a testovania, percent chyb počas trénovania a najlepšia úspešnosť

```
def train_model(model, optimizer, epochs=10):
    global save_model
    max_accuracy = 0
    accepting_rate = 0.97
    training_losses = []
    evaluation_accuracies = []

    """TTL - Time to live. If model does not update its accuracy by count
of lives,
        process of find best model will be terminated"""
    live = 50
    TTL = live

    for epoch in range(epochs):
        model.train()

        """Training information"""
        training_info = {
            'running_loss': 0.0,
            'correct': 0,
            'total': 0
        }

        for inputs, labels in train_loader:
```

```
            optimizer.zero_grad()

            outputs = model(inputs)
            loss = criterion(outputs, labels)
            loss.backward()
            optimizer.step()

            """Append training information"""
            training_info['running_loss'] += loss.item()
            _, predicted = torch.max(outputs, 1)  # predicated output
            training_info['total'] += labels.size(0)
            training_info['correct'] += (predicted == labels).sum().item()

        training_accuracy = training_info['correct'] /
training_info['total']
        training_losses.append(training_info['running_loss'] /
len(train_loader))

        """Evaluation model"""
        evaluation_accuracy = evaluate_model(model, test_loader)
        evaluation_accuracies.append(evaluation_accuracy)

        if evaluation_accuracy > max_accuracy:
            max_accuracy = evaluation_accuracy
            TTL = live
            if save_model and max_accuracy > accepting_rate:
                torch.save(model.state_dict(), 'mnist_model.pth')

        """Logging"""
        print(Fore.GREEN + "-----------------------------------------------
---------------------------------\n",
              Fore.LIGHTMAGENTA_EX + f"Epoch {epoch + 1},",
              Fore.LIGHTRED_EX + f" Train Loss:
{training_info['running_loss'] / len(train_loader):.4f}, ",
              Fore.LIGHTGREEN_EX + f"Train Accuracy:
{training_accuracy:.4f}, ",
              Fore.LIGHTCYAN_EX + f"Test Accuracy:
{evaluation_accuracy:.4f}",
              Fore.GREEN + "\n-----------------------------------------------
---------------------------------")

        if evaluation_accuracy < max_accuracy:
            TTL -= 1

        if TTL == 0:
            print(Fore.GREEN + f"Best model was not reached by {live}
hope.")
            break

    print(Fore.LIGHTGREEN_EX + "Best accuracy: ", max_accuracy)

    plot_metrics(training_losses, evaluation_accuracies)

    return model


def evaluate_model(model):
    model.eval()

    training_info = {
        'correct': 0,
```

```
        'total': 0
    }

    with torch.no_grad():
        for inputs, labels in test_loader:
            outputs = model(inputs)
            _, predicted = torch.max(outputs, 1)
            training_info['total'] += labels.size(0)
            training_info['correct'] += (predicted == labels).sum().item()

    evaluation_accuracy = training_info['correct'] / training_info['total']
    return evaluation_accuracy
```

Porovnávanie parametrov

Počas testovanie prišli sme k takým výsledným charakteristikám trénovaniach metód:

- SGD: ma pomalsiu konvergenciu v porovnaini s ostatnymi, ale výsledky je viac stabilné
- SGD s momentumom: konvergencia je rýchlejšia, ako pri SGD
- Adam: ma najrýchlejšiu konvergenciu a je oveľa presnejšia

Počas testovanie prišli sme k takým výsledným charakteristikám aktivačných funkcii:

- ReLU: oproti iných funkcii viac vyhovuje, je rýchlejšia
- Sigmoid: konvergencia je pomalšia
- Tanh: lepšia ako Sigmoid, ale horšia, ako ReLU

Počet vrstiev a ich veľkosť je tiež veľmi dôležitá. Preto potrebujeme nájsť najlepší počet vrstiev a ich rozmery.

Pri veľkej rýchlosti upečenia model môže nedoisť ku optimálnemu riešeniu. Losses môžu byt väčšie. Pri nízkej model bude pomalé hľadať optimálne riešenie, môže ovisnúť v lokálnom minimume.

Pri malej veľkosti dávky učenie je rýchlejšie, ale je menej stabilne, ako pri veľkej dávky.

Testovanie

Počas testovania používal a uviedol rôzne trénovanie metódy(sgd, sgd_momentum, adam), počet vrstiev a ich veľkosti, rôzne aktivačné funkcie(ReLU (Rectified Linear Unit), Sigmoid, Tanh), rýchlosť učenia(learning rate) a veľkosť dávky.

Prvý test som začal zo vstupnými parametrami, chcel som porovnať rôzne trénovanie metódy:

Andrii Dokaniev
id:128365 6/12/2024

```
optimizer(sgd, sgd_momentum, adam) = adam
epoch_count = 200
train_batch_size = 64
test_batch_size = 64
learning_rate = 0.001
```

Tak ako máme na vstupe obrázok 28x28, budeme mať 784 neurónov. V najprv použili sme dve vrstvy, vstupnú a výstupnú.

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 32 neurónov
- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 32
- Výstup: 10

Posledné 3 epochy(trénovanie a testovanie):

```
Epoch 18,  Train Loss: 0.0674,  Train Accuracy: 0.9793,  Test Accuracy: 0.9673
Epoch 19,  Train Loss: 0.0642,  Train Accuracy: 0.9809,  Test Accuracy: 0.9691
Epoch 20,  Train Loss: 0.0609,  Train Accuracy: 0.9813,  Test Accuracy: 0.9680
```

Ma dosť rýchly rast.

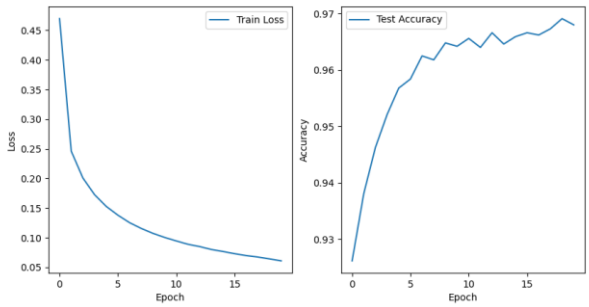


```
optimizer(sgd, sgd_momentum, adam) = sgd
epoch_count = 200
train_batch_size = 64
test_batch_size = 64
learning_rate = 0.001
```

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 32 neurónov

- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 32
- Výstup: 10

Posledné 3 epochy(trénovanie a testovanie):

```
Epoch 18,  Train Loss: 0.4669,  Train Accuracy: 0.8793,  Test Accuracy: 0.8863
Epoch 19,  Train Loss: 0.4545,  Train Accuracy: 0.8816,  Test Accuracy: 0.8878
Epoch 20,  Train Loss: 0.4439,  Train Accuracy: 0.8835,  Test Accuracy: 0.8895
```

Ako môžeme vidieť, pre tých to parametroch je dosť neúspešná, dosť malý počet epoch.

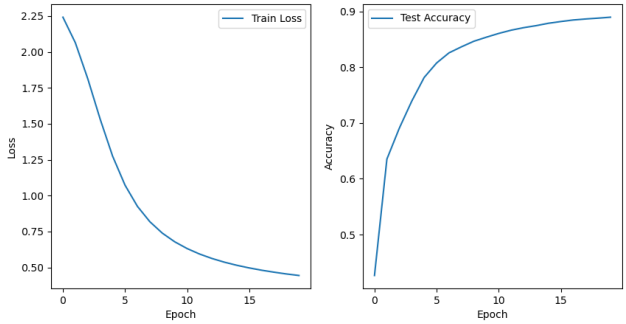


```
optimizer(sgd, sgd_momentum, adam) = sgd_momentum
epoch_count = 200
train_batch_size = 64
test_batch_size = 64
learning_rate = 0.001
momentum = 0.9
```

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 32 neurónov
- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 32
- Výstup: 10

Posledné 3 epochy(trénovanie a testovanie):

Andrii Dokaniev
id:128365
6/12/2024

```
Epoch 18,  Train Loss: 0.2210,  Train Accuracy: 0.9383,  Test Accuracy: 0.9381
Epoch 19,  Train Loss: 0.2159,  Train Accuracy: 0.9394,  Test Accuracy: 0.9404
Epoch 20,  Train Loss: 0.2114,  Train Accuracy: 0.9405,  Test Accuracy: 0.9406
```

Ako môžeme vidieť, pre tejto optimalizačnej funkcie ma stabilný rast úspešnosti, lepšie bolo b, keď sme zväčšili počet epoch.

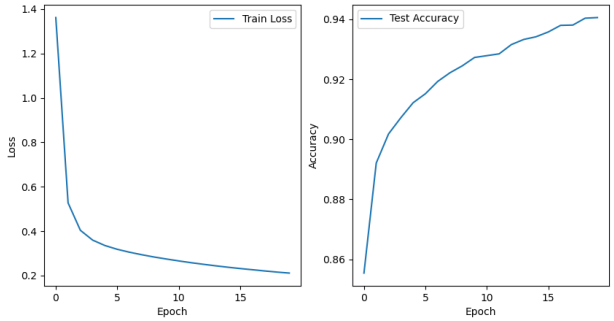

Výsledky pre rôznych aktivačných funkciách(ReLU, Sigmoid, Tanh):

Test Accuracy: 0.9554, Test Accuracy: 0.9607, Test Accuracy: 0.9541

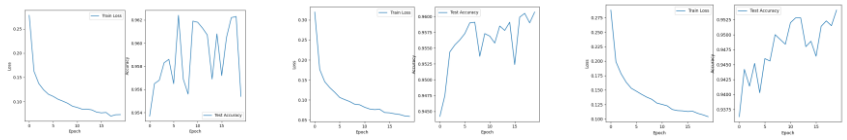

Segmid v tomto testovanii mal najlepsie vysledky z pohľadu časovej zložitosti a presnosti. Ale ReLU bol richlesij.

Z testovanie vyššie vieme, že potrebujeme zmeniť počet a rozsah vrstiev.

```
optimizer(sgd, sgd_momentum, adam) = adam
epoch_count = 20
train_batch_size = 64
test_batch_size = 64
show_confusion_matrix = False
learning_rate = 0.01
dropout (0.2)
```

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 256 neurónov
- Aktivácia: ReLU
- dropout(x)

Skrytá vrstva:

- Vstup: 256 neurónov

- Výstup: 64 neurónov
- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 64
- Výstup: 10

Posledné 3 epochy(trénovanie a testovanie):

```
Epoch 18,  Train Loss: 0.1022,  Train Accuracy: 0.9757,  Test Accuracy: 0.9732
Epoch 19,  Train Loss: 0.0923,  Train Accuracy: 0.9778,  Test Accuracy: 0.9747
Epoch 20,  Train Loss: 0.0914,  Train Accuracy: 0.9782,  Test Accuracy: 0.9762
```

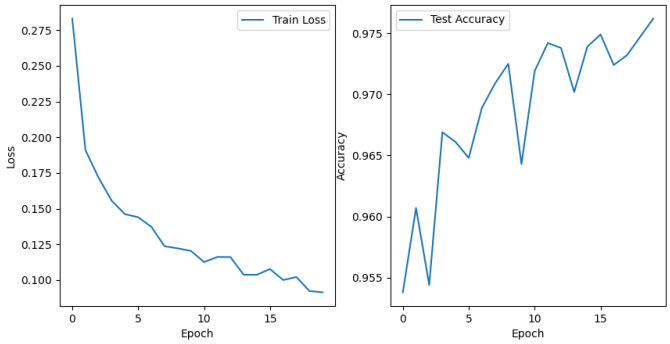

Nástupným krokom vyskúšame podobrať optimálnu rýchlosti upečenia:

Vyskúšal som znížiť lr na 0.001

```
optimizer(sgd, sgd_momentum, adam) = adam
epoch_count = 20
train_batch_size = 64
test_batch_size = 64
show_confusion_matrix = False
learning_rate = 0.001
dropout (0.2)
```

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 256 neurónov
- Aktivácia: ReLU
- dropout(x)

Skrytá vrstva:

- Vstup: 256 neurónov
- Výstup: 64 neurónov
- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 64
- Výstup: 10

Posledné 3 epochy(trénovanie a testovanie):

```
Epoch 18,  Train Loss: 0.0101,  Train Accuracy: 0.9966,  Test Accuracy: 0.9800
Epoch 19,  Train Loss: 0.0075,  Train Accuracy: 0.9973,  Test Accuracy: 0.9781
Epoch 20,  Train Loss: 0.0071,  Train Accuracy: 0.9978,  Test Accuracy: 0.9796
```

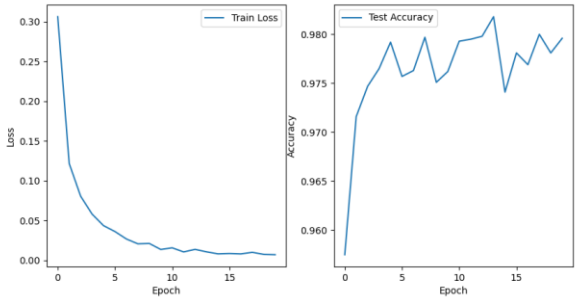

Výsledok je oveľa lepší ako pri 0.01

Pri nasledujúcich testovaniach som doimplementoval vypísanie najlepšieho dosiahnutého výsledku.

```
optimizer(sgd, sgd_momentum, adam) = adam
epoch_count = 200
train_batch_size = 64
test_batch_size = 64
learning_rate = 0.001
```

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 256 neurónov
- Aktivácia: ReLU

Skrytá 1 vrstva:

- Vstup: 256 neurónov
- Výstup: 64 neurónov
- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 64
- Výstup: 10

Andrii Dokaniev
id:128365
6/12/2024

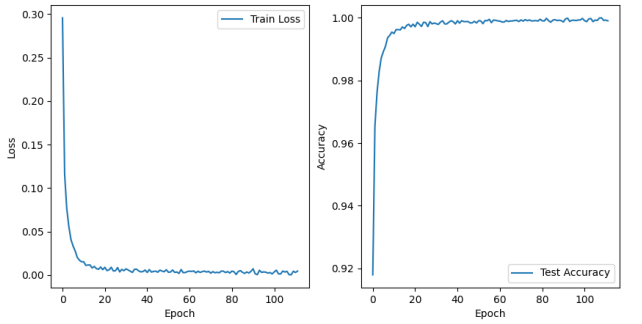

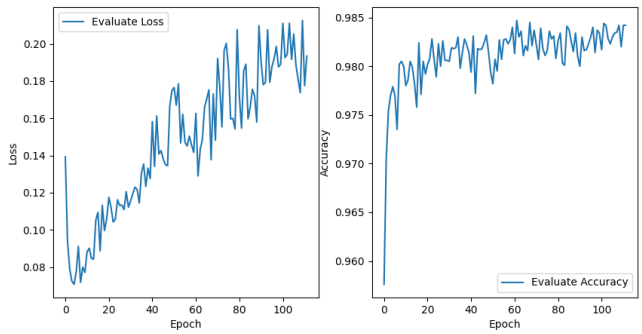

V tomto prípade mame overfitting.

Best epoch 61 with:Train Loss: 0.0042, Train Accuracy: 0.9987, Test Loss: 0.1290, Test Accuracy: 0.9847

```
optimizer(sgd, sgd_momentum, adam) = adam
epoch_count = 200
train_batch_size = 64
test_batch_size = 64
learning_rate = 0.001
```

Vstupná vrstva:

- Vstup: 784 neurónov
- Výstup: 256 neurónov
- Aktivácia: ReLU

Skrytá 1 vrstva:

- Vstup: 256 neurónov
- Výstup: 128 neurónov
- Aktivácia: ReLU

Skrytá 2 vrstva:

- Vstup: 128 neurónov
- Výstup: 64 neurónov
- Aktivácia: ReLU

Výstupná vrstva:

- Vstup: 64
- Výstup: 10

Andrii Dokaniev
id:128365

6/12/2024

Posledné 3 epochy(trénovanie a testovanie):

Najlepšia uspesnost: 98.64+

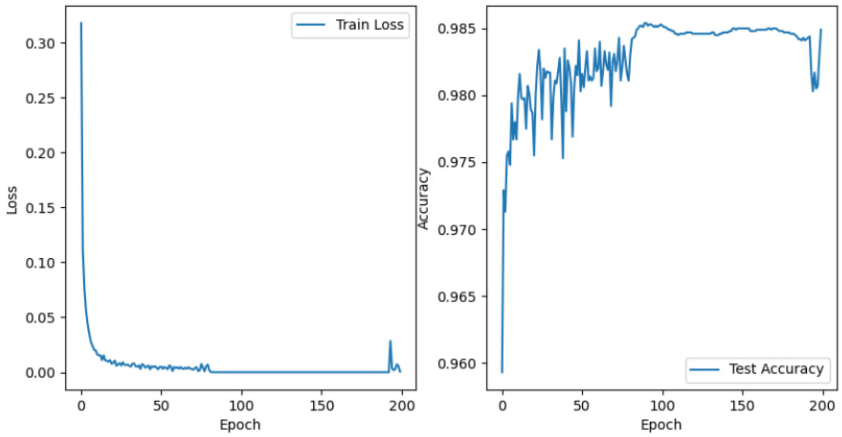

Andrii Dokaniev
id:128365 6/12/2024

Zhodnotenie

Vytvorená neurónová sieť na klasifikáciu ručne písaných číslic z dátového súboru MNIST je určený na trénovanie a testovanie vytvoreného systému s rôznymi parametrami, ako napríklad: optimalizačný metód, vhodné aktivačné funkcie, rýchlosť učenia a veľkosť dávky (batch) pre optimalizačný algoritmus. Taktiež treba bolo cestou pokusov a omylov navrhnúť počet vrstiev a ich veľkosti pre vytvorenú model. Otestovať, porovnať výsledky testovania a vyhodnotiť úspešnosť nerehneného modelu.

Výtvory, natrénovaný model je schopný klasifikovať číslice s percentom úspešnosti 98 a vyššie. Závisí od poctu epoch a nastavení modelu na trénovaní. Najlepší výsledok bol opísaný v testovacej časti a dokázal schopnosť siete riešiť podobne problémy na klasifikáciu číslic.

Taktiež program umožňuje konfigurovať konfiguráciu pred behom programu. Čo výrazne zrýchľuje prístup k jednotným špecifikáciám a prispôsobeným nástrojom pre určite potreby klienta. Ako napríklad používateľ môže si zvoliť spôsob učenia site, aká najviac mu vyhovuje.

Dosť dôležitou úlohou bolo správne vybrať a nastrojiť parametre pre učenia. Boli porovnané rôzne spôsoby konfigurácie, a navrhnutá najlepšia konfigurácia, ktorú sa dala vytvoriť.